Pyspark 安裝教學


Step 1:

下載安裝 python3.5.x 或 python 3.6.x, 並加入環境變數 (建議不要用 Anaconda 下載)

Step 2:


(1) 安裝 Java 8 (注意 Java 版本)

https://www.oracle.com/technetwork/java/javase/downloads/jdk8-downloads-2133151.html




(2) 設定環境變數(JAVA_HOME & path)

設定 JAVA HOME 環境變數,jdk 位置請設定為自己下載的jdk 的位置。



設定 path 環境變數,位置設為 jdk 裡面的 bin 資料夾。



Step 3:

(1) 下載 spark, http://spark.apache.org/downloads.html

Download Apache Spark™


- Choose a Spark release: 2.4.4 (Aug 30 2019) ▼
- 2. Choose a package type: Pre-built for Apache Hadoop 2.7 and later ▼
- Download Spark: spark-2.4.4-bin-hadoop2.7.tgz
- Verify this release using the 2.4.4 signatures, checksums and project release KEYS.

Note that, Spark is pre-built with Scala 2.11 except version 2.4.2, which is pre-built with Scala 2.12.

(2) 設定環境變數(SPARK HOME & HADOOP HOME)

位置請改為自己下載 Spark 的

JAVA_HOME



C:\Program Files\Java\jdk1.8.0_221

編輯(I)...


刪除(L)

新增(W)...

Step 4:

Windows 請下載對應的 hadoop 版本的 winutils.exe

https://github.com/steveloughran/winutils



下載後放入 spark 中的 bin 資料夾內

Step 5:

安裝 jupyter notebook, cmd 輸入 pip install jupyter

設定環境變數(PYSPARK_DRIVER_PYTHON &

PYSPARK_DRIVER_PYTHON_OPTS)

編輯系統變數		×
變數名稱(N):	PYSPARK_DRIVER_PYTHON	
變數值(V):	jupyter	
瀏覽目錄(D)	瀏覽檔案(F)	確定 取消

編輯系統變數		X
變數名稱(N):	PYSPARK_DRIVER_PYTHON_OPTS '	
變數值(V):	notebook	
瀏覽目錄(D)	瀏覽檔案(F) 取消	

Step 6:

cmd 輸入 pyspark 會開啟 jupyter,可測試是否安裝成功